

YouTube Trending Video Dataset — Аналитички извештај

Давор Хома

2026-05-24

1. Избор скупа података

За потребе пројекта одабран је скуп података „All Regions Youtube Trending Video Dataset”, доступан на Kaggle платформи. Оригинални извор података је скуп YouTube Trending Video Dataset аутора Ришав Шарма, док је коришћена верзија додатно унапређена кроз проширење атрибута коришћењем YouTube API-ја и обједињавање више региона у јединствен скуп података.

Скуп података има укупну величину од приближно 4,55 GB, што га сврстава у категорију великих скупова података погодних за анализу великих количина података.

Сваки запис у скупу података представља један YouTube видео запис који се у одређеном тренутку (`trending_date`) налазио на листи трендова. Скуп података не садржи све YouTube видео записе, већ искључиво оне који су достигли статус трендинг видео записа у оквиру посматраног временског периода.

Важно је напоменути да скуп података поседује природну денормализацију: исти видео запис може се појавити више пута уколико је био трендинг у различитим временским периодима. Овај аспект је адресиран у фази припреме података кроз одговарајуће агрегације.

1.1 Атрибути скупа података

Скуп података садржи следећа обележја:

Табела 1: Атрибути скупа података

Обележје	Опис
<code>video_id</code>	Јединствени идентификатор видео записа
<code>title</code>	Назив видео записа
<code>publishedAt</code>	Датум и време објављивања видео записа
<code>channelId</code>	Идентификатор YouTube канала
<code>channelTitle</code>	Назив YouTube канала
<code>categoryId</code>	Категорија видео записа
<code>trending_date</code>	Датум када је видео био у трендинг секцији
<code>tags</code>	Ознаке повезане са видео записом
<code>view_count</code>	Број прегледа
<code>likes</code>	Број позитивних реакција

Обележје	Опис
dislikes	Број негативних реакција
comment_count	Број коментара
thumbnail_link	Линк ка thumbnail слици
comments_disabled	Информација да ли су коментари онемогућени
ratings_disabled	Информација да ли су реакције онемогућене
description	Опис видео записа
duration_seconds	Трајање у секундама (изведено из ISO 8601 формата)

Разноврсност атрибута омогућава смислено спровођење прелиминарне анализе података, класификације, кластеризације, као и визуелизације различитих образаца понашања трендинг видео садржаја на платформи YouTube.

Посебна предност овог скупа је велика количина података, као и присуство података из различитих региона и категорија садржаја, што омогућава детаљнију анализу карактеристика видео записа који остварују високу популарност на платформи.

2. Припрема података

2.1 Учитавање података

Подаци су учитани у R окружење коришћењем пакета `sparklyr` и функције `spark_read_csv`. Циљ је било омогућити ефикасно учитавање великог скупа података без непотребног оптерећења меморије.

```
sc <- spark_connect(master = "local[*]")

dataset <- spark_read_csv(
  sc,
  name = "youtube",
  path = "data/all_regions_youtube_trending_data_with_duration.csv",
  header = TRUE,
  infer_schema = TRUE
)

dataset <- dataset %>%
  clean_names() %>%
  mutate(
    view_count      = as.numeric(view_count),
    likes           = as.numeric(likes),
    dislikes        = as.numeric(dislikes),
    comment_count   = as.numeric(comment_count),
    published_at    = to_date(published_at),
    trending_date   = to_date(trending_date),
    category_id     = as.numeric(category_id),
    duration        = as.character(duration)
  )
```

2.2 Чишћење података

Уклоњени су дупликати по пару (video_id, trending_date) коришћењем функције distinct(), чиме је обезбеђено да сваки трендинг догађај буде заступљен тачно једном пре агрегације.

```
youtube_clean <- dataset %>%  
  distinct(video_id, trending_date, .keep_all = TRUE)
```

2.3 Обрада недостајућих вредности

Анализирано је присуство недостајућих вредности у свим колонама скупа података. Примењене су следеће стратегије:

- уклањање редова са недостајућим вредностима обавезних поља (video_id, trending_date, view_count)

```
youtube_clean <- youtube_clean %>%  
  filter(  
    !is.na(video_id),  
    !is.na(trending_date),  
    !is.na(view_count) | view_count == 0  
  )
```

- импутација медијаном за нумеричке атрибуте view_count, likes и comment_count

```
# Izracunavanje medijana na Spark skupu  
medians <- youtube_clean %>%  
  summarise(  
    view_med      = percentile_approx(view_count, 0.5),  
    likes_med     = percentile_approx(likes, 0.5),  
    comments_med  = percentile_approx(comment_count, 0.5)  
  ) %>%  
  collect()  
  
# Imputacija medijanom  
youtube_clean <- youtube_clean %>%  
  mutate(  
    view_count     = ifelse(is.na(view_count) | view_count == 0,  
                           medians$view_med, view_count),  
    likes          = ifelse(is.na(likes), medians$likes_med, likes),  
    comment_count  = ifelse(is.na(comment_count),  
                           medians$comments_med, comment_count)  
  )
```

Напомена о атрибуту dislikes: од 2021. године, YouTube је уклонио јавни приказ броја негативних реакција, што је резултовало тиме да у овом скупу података 68% вредности овог атрибута недостаје. Због тога dislikes није коришћен као предикторско обележје у анализи.

2.4 Текстуална поља

Атрибути title, tags и description нису укључени у класификацију и кластеризацију. Разлог за ово искључење је обим пројекта. NLP обрада текста представља посебну целину која би повећала сложеност анализе.

2.5 Трансформација атрибута

Атрибут duration_seconds изведен је из ISO 8601 формата (PT1H23M45S) применом регуларних израза.

```
# Izvođenje duration_seconds iz ISO 8601 formata
youtube_clean <- youtube_clean %>%
  mutate(
    duration = coalesce(duration, "PT0S"),
    h = as.integer(rebexp_extract(duration, "([0-9]+)H", 1)),
    m = as.integer(rebexp_extract(duration, "([0-9]+)M", 1)),
    s = as.integer(rebexp_extract(duration, "([0-9]+)S", 1)),
    duration_seconds = as.integer(
      coalesce(h, 0L) * 3600L +
      coalesce(m, 0L) * 60L +
      coalesce(s, 0L)
    )
  )
```

Атрибут category_id је пресликан на одговарајући текстуални назив категорије (category_name) путем унапред дефинисане мапе. У скупу се налазе **15 различитих вредности циљног обележја** иако YouTube дефинише више од 15 категорија.

```
# Mapiranje category_id na naziv kategorije
category_map <- data.frame(
  category_id = c(
    1, 2, 10, 15, 17,
    18, 19, 20, 21, 22,
    23, 24, 25, 26, 27,
    28, 29, 30, 31, 32,
    33, 34, 35, 36, 37,
    38, 39, 40, 41, 42,
    43, 44, -1
  ),
  category_name = c(
    "Film & Animation",
    "Autos & Vehicles",
    ...
  )
)
category_map$category_id <- as.integer(category_map$category_id)
category_map_spark <- copy_to(sc, category_map, overwrite = TRUE)

youtube_clean <- youtube_clean %>%
  left_join(category_map_spark, by = "category_id")
```

2.6 Адресирање денормализације

Будући да се исти видео запис може појавити више пута у скупу података, извршена је агрегација по `video_id`. За потребе класификације и кластеризације креиран је агрегирани скуп са једним записом по видеу, коришћењем максималних вредности нумеричких атрибута (врхунац популарности). Поред тога, током агрегације је израчунат атрибут `trending_count` који означава број пута колико је одређени видео запис био у трендовима и биће употребљен за кластеризацију.

```
youtube_aggregated <- youtube_clean %>%
  group_by(video_id, category_id, category_name) %>%
  summarise(
    view_count      = max(view_count, na.rm = TRUE),
    likes           = max(likes, na.rm = TRUE),
    comment_count   = max(comment_count, na.rm = TRUE),
    duration_seconds = max(duration_seconds, na.rm = TRUE),
    trending_count  = n(),
    .groups = "drop"
  )
```

2.7 Извођење нових атрибута

На основу постојећих нумеричких атрибута изведена су два нова обележја која боље описују ангажованост гледалаца:

- `like_rate` = `likes / view_count` – стопа позитивних реакција
- `comment_rate` = `comment_count / view_count` – стопа коментара

Атрибут `engagement_rate` = `(likes + comment_count) / view_count` је разматран као кандидат, али је искључен због готово савршене корелације са `like_rate` ($r = 0,992$), што би унело редундантност у предикторски скуп.

```
youtube_aggregated <- youtube_aggregated %>%
  mutate(
    like_rate   = likes / view_count,
    comment_rate = comment_count / view_count
  ) %>%
  filter(
    view_count > 0,
    !is.na(like_rate),
    !is.na(comment_rate)
  )
```

3. Прелиминарна анализа података

3.1 Дескриптивна статистика

За свих шест нумеричких обележја израчунате су основне дескриптивне статистике: средња вредност, медијана, стандардна девијација, минимум, максимум и кватили.


```
num_stats <- youtube_data %>%
  summarise(
    view_mean = mean(view_count, na.rm = TRUE),
    view_median = percentile_approx(view_count, 0.5),
    view_sd = sd(view_count, na.rm = TRUE),
    view_min = min(view_count, na.rm = TRUE),
    view_max = max(view_count, na.rm = TRUE),
    view_q1 = percentile_approx(view_count, 0.25),
    view_q3 = percentile_approx(view_count, 0.75),
    # ... (analogno za likes, comment_count, duration_seconds, like_rate, comment_rate)
  ) %>%
  collect()
```

Анализа дескриптивних статистика открива изражену десну асиметрију код свих обележја повезаних са популарношћу (`view_count`, `likes`, `comment_count`). Медијана је знатно нижа од средње вредности, што указује на присуство малог броја видео записа са изузетно великим вредностима.


3.2 Визуализација расподела

Хистограми


Расподеле нумеричких обележја приказане су на логаритамској скали X осе, јер сирове вредности показују јаку десну асиметрију.




Слика 1: Расподела броја прегледа




Слика 2: Расподела броја лајкова




Слика 3: Расподела броја коментара



Слика 4: Расподела трајања видео записа



Слика 5: Расподела стопе лајкова




Слика 6: Расподела стопе коментара


Код свих шест обележја хистограми на $\log$ скали показују приближно симетричну расподелу, и може се закључити да подаци имају $\log$ -нормалну природу. Изведени атрибути `like_rate` и `comment_rate` такође показују сличан образац.

Boxplot графикони


Boxplot графикони омогућавају визуелну детекцију аутлајера. Приказани су такође на логаритамској скали.




Слика 7: Вохplot броја прегледа




Слика 8: Вохplot броја лајкова




Слика 9: Вохplot броја коментара



Слика 10: Вохplot трајања видео записа



Слика 11: Boxplot стопе лајкова




Слика 12: Boxplot стопе коментара

Код свих обележја уочава се значајан број аутлајера изнад горњег квантила, нарочито код `view_count` и `likes`, где поједини видео записи остварују вредности неколико редова величине изнад медијане.

Расподела по категоријама

Bar plot приказује број видео записа по свакој од 15 категорија циљног обележја `category_name`. Овај приказ је посебно важан јер омогућава увид у потенцијалну неуравнотеженост класа.




Слика 13: Број видео записа по категорији

Из графика је јасно видљива изражена неуравнотеженост класа. Категорије попут „Entertainment“, „People & Blogs“ и „Gaming“ значајно доминирају над категоријама попут „Nonprofits & Activism“ или „Pets & Animals“.

3.3 Анализа односа између обележја

Корелациона анализа

```
numeric_data <- youtube_sample %>%  
  select(view_count, likes, comment_count,  
         duration_seconds, like_rate, comment_rate)  
  
cor_matrix <- cor(numeric_data, use = "complete.obs")
```




Слика 14: Корелациона матрица нумеричких варијабли


Корелациона матрица потврђује очекивано јаку позитивну корелацију између `view_count`, `likes` и `comment_count`. Атрибут `duration_seconds` показује слабу корелацију са осталим обележјима, чиме потврђује своју информативну вредност као независан предиктор. Изведени атрибути `like_rate` и `comment_rate` показују слабу корелацију са апсолутним бројевима, чиме се потврђује да носе различиту информацију. Такође, корелација између `like_rate` и `comment_rate` је умерена ($r \approx 0,37$), а не блиска 1, за разлику од претходно разматраног `engagement_rate`, па оба атрибута оправдано остају у предикторском скупу.

Scatter plot анализа


Scatter plot графикони приказују однос парова нумеричких варијабли на log-log скали.




Слика 15: Број прегледа vs. број лајкова




Слика 16: Број прегледа vs. број коментара



Слика 17: Број лајкова vs. број коментара



Слика 18: Трајање vs. број прегледа




Слика 19: Стопа лајкова vs. стопа коментара


Scatter plot `view_count` vs. `likes` и `view_count` vs. `comment_count` показују јасну линеарну везу на log-log скали, у складу са корелационом матрицом. Однос трајања и броја прегледа не показује јасан линеарни образац, што потврђује да `duration_seconds` носи независну информацију.

Однос категоријских и нумеричких обележја


Boxplot графикони приказују расподелу нумеричких обележја унутар сваке категорије, омогућавајући увид у то да ли категорија видео записа утиче на обрасце популарности и ангажованости.




Слика 20: Број прегледа по категорији




Слика 21: Број лајкова по категорији




Слика 22: Број коментара по категорији



Слика 23: Стопа лајкова по категорији



Слика 24: Стопа коментара по категорији



Слика 25: Трајање по категорији

Посматрајући дистрибуцију трајања видео записа, категорије попут „Travel & Events”, „Autos & Vehicles” и „Gaming” имају најдуже видео записе, док се „Music” издваја са знатно краћим садржајем и уском расподелом. Категорија „Film & Animation” показује највећу варијабилност у трајању.

„Music”, „Entertainment” и „Comedy” категорије имају највећи број прегледа (view_count), док „Autos & Vehicles” бележи најмањи.

Интересантан податак је да „Science & Technology” и „Comedy” остварују највише стопе лајковања (like_rate), упркос томе што нису на врху по броју прегледа. Ово указује на активну публику.

4. Класификација

4.1 Поставка проблема

Циљно обележје је категорија YouTube видео записа (category_name). Ради се о вишекласној класификацији са **15 различитих класа**. Предиктори коришћени у свим моделима су: view_count, likes, comment_count, duration_seconds, like_rate и comment_rate.

Атрибут dislikes је искључен због 68% недостајућих вредности. Текстуална поља (title, tags, description) нису укључена у анализу (видети одељак 2.4).

Скуп података је подељен у односу 80/20 на тренинг и тест скуп, са фиксираним seed-ом ради поновљивости мерења. Исти seed је коришћен у све три класификационе методе ради конзистентности поређења.

```
splits <- sdf_random_split(ml_data, training = 0.8, test = 0.2, seed = 42L)
train_data <- sdf_persist(splits$training, storage.level = "MEMORY_AND_DISK")
test_data <- sdf_persist(splits$test, storage.level = "MEMORY_AND_DISK")
```

За оцену перформанси коришћене су следеће метрике: **тачност** (accuracy), макро **прецизност** (precision), макро **осетљивост** (sensitivity) и макро **F1 скор**. Макро просек је одабран јер третира све класе равноправно, без обзира на величину, а с обзиром на изражену неуравнотеженост класа то је посебно значајно. Перформансе су процењене и путем 3-fold унакрсне валидације, имплементиране ручно над Spark DataFrame-овима.

```
build_cv_pipeline <- function(alpha, lambda, train_sdf, k = 3) {
  fold_weights <- setNames(rep(1 / k, k), paste0("fold", seq_len(k)))
  folds <- sdf_random_split(train_sdf, weights = fold_weights, seed = 42L)

  fold_accuracies <- numeric(k)
  for (i in seq_len(k)) {
    val_fold <- folds[[i]]
    train_fold <- do.call(sdf_bind_rows, folds[-i])
    fitted <- ml_fit(pipeline, train_fold)
    preds <- ml_transform(fitted, val_fold) %>%
      select(label, prediction) %>% collect()
    fold_accuracies[i] <- mean(preds$label == preds$prediction)
  }
  mean(fold_accuracies)
}
```


4.2 Логистичка регресија

Примењена је мултиномијална логистичка регресија путем Spark ML `ml_logistic_regression` са параметром `family = "multinomial"`. Испитана су три сценарија варирањем параметра регуларизације `elastic_net_param` (α) и јачине регуларизације `reg_param` (λ):


- **Сценарио 1:** L2 регуларизација ($\alpha = 0$), $\lambda = 0,001$, слаба регуларизација, модел може да се боље прилагоди подацима
- **Сценарио 2:** L2 регуларизација ($\alpha = 0$), $\lambda = 0,1$, јача регуларизација, смањује ризик од оверфитинга
- **Сценарио 3:** L1 регуларизација / Lasso ($\alpha = 1$), $\lambda = 0,01$, уводи ретке тежине, потенцијално бирање обележја

Предиктори су стандардизовани путем `ft_standard_scaler` јер је логистичка регресија са регуларизацијом осетљива на скалу улазних обележја.


```
pipeline <- ml_pipeline(sc) %>%
  ft_string_indexer(input_col = "category_name", output_col = "label") %>%
  ft_vector_assembler(input_cols = predictors, output_col = "features_raw") %>%
  ft_standard_scaler(
    input_col = "features_raw", output_col = "features",
    with_mean = TRUE, with_std = TRUE
  ) %>%
  ml_logistic_regression(
    features_col = "features",
    label_col = "label",
    elastic_net_param = alpha, # 0 = L2 (Ridge), 1 = L1 (Lasso)
    reg_param = lambda,
    max_iter = 30,
    family = "multinomial"
  )
```



Слика 26: Поређење сценарија логистичке регресије



Слика 27: Матрица конфузије за најбољи сценарио LR



Слика 28: F1 по категорији ус најбољи сценарио LR

4.3 Метод потпорних вектора (SVM)

Примењен је линеарни SVM путем Spark ML `ml_linear_svc`. Будући да Spark ML имплементира искључиво бинарни SVM класификатор, за вишекласни проблем (15 категорија) коришћена је One-vs-Rest (OvR) стратегија: за сваку класу тренира се засебан бинарни класификатор (класа vs све остале класе), а финална предикција доноси се на основу највеће маргине.

Испитана су три сценарија варирањем параметра L2 регуларизације `reg_param` и броја итерација `max_iter`:

- **Сценарио 1:** `reg_param = 0,001`, `max_iter = 5`, слаба регуларизација, мање итерација
- **Сценарио 2:** `reg_param = 0,1`, `max_iter = 5`, јака регуларизација, мање итерација
- **Сценарио 3:** `reg_param = 0,001`, `max_iter = 10`, слаба регуларизација, више итерација

Стандардизација је обавезна јер је SVM посебно осетљив на скалу улазних обележја.


```
pipeline <- ml_pipeline(sc) %>%
  ft_string_indexer(input_col = "category_name", output_col = "label") %>%
  ft_vector_assembler(input_cols = predictors, output_col = "features_raw") %>%
  ft_standard_scaler(
    input_col = "features_raw", output_col = "features",
    with_mean = TRUE, with_std = TRUE
  ) %>%
  ml_one_vs_rest(
    classifier = ml_linear_svc(
      sc,
      features_col = "features",
      label_col = "label",
```




```

    reg_param    = reg_param,
    max_iter     = max_iter
),
features_col = "features",
label_col    = "label"
)


```



Слика 29: Поређење сценарија — SVM



Слика 30: Матрица конфузије за најбољи сценарио SVM



Слика 31: F1 по категорији за најбољи сценарио SVM

4.4 Random Forest

Примењен је Random Forest путем Spark ML `ml_random_forest_classifier`, који директно подржава вишекласну класификацију без потребе за OvR стратегијом. Алгоритам гради ансамбл стабала одлучивања и комбинује њихове предикције гласањем.

За разлику од LR и SVM, Random Forest не захтева стандардизацију улазних обележја. Такође, природно је робустан на неуравнотеженост класа јер сваки чвор стабла бира поделу која максимизује чистоћу класа независно.

Испитана су три сценарија варирањем броја стабала `num_trees`, максималне дубине `max_depth` и минималног броја инстанци у листу `min_instances_per_node`:


- **Сценарио 1:** `num_trees = 50`, `max_depth = 5`, `min_inst = 1`, основна линија
- **Сценарио 2:** `num_trees = 100`, `max_depth = 5`, `min_inst = 1`, већи ансамбл, стабилнија предикција
- **Сценарио 3:** `num_trees = 50`, `max_depth = 8`, `min_inst = 5`, `max_bins = 16`, комплекснији модел; `max_depth` је ограничен на 8 јер број чворова расте експоненцијално са дубином (2^{depth}), па би `max_depth = 10 \times 100` стабала изазвао OOM грешку на JVM heap-у

```
pipeline <- ml_pipeline(sc) %>%
  ft_string_indexer(input_col = "category_name", output_col = "label") %>%
  ft_vector_assembler(input_cols = predictors, output_col = "features") %>%
  ml_random_forest_classifier(
    features_col      = "features",
    label_col         = "label",
    num_trees         = num_trees,
    max_depth         = max_depth,
    min_instances_per_node = min_instances_per_node,
    max_bins          = max_bins,
    seed              = 42L
  )
```


Поред стандардних метрика, за Random Forest израчуната је и важност обележја (`feature importance`) на основу просечног смањења Gini нечистоће кроз сва стабла — ово је једна од кључних предности RF-а у односу на LR и SVM.

```
best_rf_model      <- ml_stages(best_rf$pipeline)[[3]]
feature_importances <- ml_feature_importances(best_rf_model)


fi_df <- data.frame(feature = predictors, importance = feature_importances) %>%
  arrange(desc(importance))
```




Слика 32: Поређење сценарија Random Forest



Слика 33: Матрица конфузије за најбољи сценарио RF



Слика 34: F1 по категорији за најбољи сценарио RF




Слика 35: Важност обележја за Random Forest

4.5 Поређење и избор модела


Резултати сва три алгоритма учитани су из сачуваних `.rds` фајлова без поновног тренирања, а затим упоређени по свим метрикама.

```
lr_saved <- readRDS("models/lr_best_results.rds")
svm_saved <- readRDS("models/svm_best_results.rds")
rf_saved <- readRDS("models/rf_best_results.rds")
```




Слика 36: Поређење алгоритама по кључним метрикама

Поред поређења метрика на тест скупу, анализирана је и **стабилност модела** кроз разлику између Cross-validation (CV) accuracy и test accuracy. Ове разлике су веома мале, што говори да није дошло до оверфитинга (слика 37).



Слика 37: Стабилност модела - CV accuracy vs. test accuracy



Слика 38: Поређење F1 по категорији свих алгоритама

На основу резултата може се закључити да је Random Forest модел остварио најбоље перформансе у свим посматраним метрикама, са тачношћу ~ 0.33 . Logistic Regression модел даје тачност ~ 0.27 , док је SVM модел показао најслабије перформансе (~ 0.20).

Добијене вредности метрика указују да је задатак класификације YouTube категорија на основу искључиво нумеричких атрибута релативно тежак, што је очекивано имајући у виду велики број класа и одсуство текстуалних информација. Укључивање текстуалних обележја (title, tags, description) и напредних NLP техника потенцијално би могло значајно побољшати перформансе модела.

5. Кластеризација

5.1 Поставка проблема

Примењен је K-means алгоритам са циљем груписања YouTube видео записа на основу њихових нумеричких карактеристика и идентификације природних образаца у подацима.

Коришћена су два скупа атрибута:

- **Основни скуп:** view_count, likes, comment_count, duration_seconds, like_rate, comment_rate - идентичан предикторском скупу из класификације
- **Проширени скуп:** основни скуп + trending_count - број пута колико је видео био trending. мери колико дуго је видео остао популаран и може раздвојити кластере краткорочних и дугорочних trending видео записа

Пре примене алгоритма, атрибути су стандардизовани (mean = 0, std = 1) путем ft_standard_scaler, јер K-means користи еуклидску дистанцу. Атрибути са већим распонем (нпр. view_count $\sim 10^6$) би без стандардизације доминирали над атрибутима са мањим распонем (нпр. like_rate $\sim 0,01$).

```
build_kmeans <- function(train_sdf, predictors, k, seed = 42L) {  
  prep_pipeline <- ml_pipeline(sc) %>%  
    ft_vector_assembler(  
      input_cols = predictors,  
      output_col = "features_raw"  
    ) %>%  
    ft_standard_scaler(  
      input_col = "features_raw", output_col = "features_scaled",  
      with_mean = TRUE, with_std = TRUE  
    )  
  
  prep_fitted <- ml_fit(prepare_pipeline, train_sdf)  
  scaled_sdf <- ml_transform(prepare_fitted, train_sdf)  
  
  kmeans_model <- ml_kmeans(  
    scaled_sdf,  
    formula = ~features_scaled,  
    k = k,  
    seed = seed,  
    max_iter = 100L,  
    init_steps = 5L  
  )  
}
```



```

)

predictions <- ml_predict(kmeans_model, scaled_sdf)
wcss <- ml_summary(kmeans_model)$training_cost

list(pipeline = kmeans_model, predictions = predictions, wcss = wcss, k = k)
}

```

5.2 Одређивање оптималног броја кластера помоћу Elbow методе

Пре дефинисања сценарија, примењена је Elbow метода за одређивање оптималног броја кластера. K-means је покренут за вредности k од 2 до 10 на основном скупу атрибута, а праћена је вредност WCSS (within-cluster sum of squares).


```

elbow_k_values <- 2:10
elbow_wcss <- numeric(length(elbow_k_values))

for (i in seq_along(elbow_k_values)) {
  result <- build_kmeans(cluster_data, predictors_basic, k = elbow_k_values[i])
  elbow_wcss[i] <- result$wcss
}

elbow_df <- data.frame(k = elbow_k_values, wcss = elbow_wcss)

```



Слика 39: Elbow метода за одређивање оптималног k

На основу Elbow графика одабране су вредности $k = 4$ и $k = 6$ за даљу анализу:

- **$k = 4$** - мањи број кластера; очекују се грубе групе по популарности (нпр. вирални, популарни, просечни, нишни видео записи)

- **k = 6** – већи број кластера; финија подела која може открити разлике унутар популарних категорија (кратак vs. дугачак садржај, висока vs. ниска стопа коментара)

5.3 Сценарији кластеризације


Испитана су четири сценарија комбинацијом два броја кластера и два скупа атрибута:

- **Сценарио А:** $k = 4$, основни атрибути
- **Сценарио Б:** $k = 4$, проширени атрибути
- **Сценарио Ц:** $k = 6$, основни атрибути
- **Сценарио Д:** $k = 6$, проширени атрибути

```
kmeans_scenarios <- list(
  list(name = "Scenario A: k=4, basic features",
        k = 4, predictors = predictors_basic, pred_label = "basic"),
  list(name = "Scenario B: k=4, extended features",
        k = 4, predictors = predictors_extended, pred_label = "extended"),
  list(name = "Scenario C: k=6, basic features",
        k = 6, predictors = predictors_basic, pred_label = "basic"),
  list(name = "Scenario D: k=6, extended features",
        k = 6, predictors = predictors_extended, pred_label = "extended")
)
```

Поређење WCSS вредности свих сценарија приказано је на следећем графику. Очекивано, сценарији са $k = 6$ остварују нижи WCSS јер се са више кластера боље процењује структура података.

Проширени скуп атрибута производи виши WCSS него основни при истом k , јер додатна димензија (trending_count) повећава укупну варијансу у простору.



Слика 40: Поређење WCSS по сценаријима

5.4 Анализа структуре кластера


За сваки сценарио анализиране су величине кластера и просечне вредности атрибута по кластеру. Просечне вредности су нормализоване на опсег [0, 1] по колонама ради поређења атрибута различитих скала.

```
analyze_clusters <- function(predictions_sdf, predictors, k) {  
  cluster_sizes <- predictions_sdf %>%  
    count(prediction) %>% arrange(prediction) %>% collect()  
  
  cluster_means <- predictions_sdf %>%  
    group_by(prediction) %>%  
    summarise(across(all_of(predictors), mean, na.rm = TRUE), .groups = "drop") %>%  
    arrange(prediction) %>% collect()  
  
  list(cluster_sizes = cluster_sizes, cluster_means = cluster_means)  
}
```


5.5 Визуализација кластера

Scatter plot графикони


Scatter plot графикони приказују расподелу видео записа у 2D простору (view_count vs. like_rate) са обојеним кластерима. Коришћен је 5% узорак ради перформанси визуализације.




Слика 41: Scatter plot кластера за Сценарио А



Слика 42: Scatter plot кластера за Сценарио Б




Слика 43: Scatter plot кластера за Сценарио Ц




Слика 44: Scatter plot кластера за Сценарио Д

Профили кластера (heatmap)


Heatmap графикони приказују нормализоване просечне вредности атрибута по кластеру, омогућавајући интерпретацију карактера сваког кластера.




Слика 45: Профил кластера за Сценарио А



Слика 46: Профил кластера за Сценарио Б



Слика 47: Профил кластера за Сценарио Ц



Слика 48: Профил кластера за Сценарио Д

Профили кластера откривају конзистентну структуру кроз све сценарије. У свим случајевима јасно се издваја мали кластер видео записа са изузетно великим бројем прегледа, лајкова и коментара (вирални садржај), као и кластер са високом стопом лајкова при ниском апсолутном броју прегледа (нишни, ангажован садржај). Остали кластери углавном представљају просечне видео записе, раздвојених претежно по трајању.

У сценарију Д додавање `trending_count` атрибута довело је до формирања посебног кластера видео записа са умереним трендинг присуством и вишом стопом лајкова, што сугерише да дугорочно популарни видео записи имају другачији профил од краткорочно виралних.